

UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE COMPUTAÇÃO

Sistema Inteligente de Triagem em Pronto-Socorro

Utilizando Redes Bayesianas e Algoritmo A*

Francisco Wilton – 508586

Jardel de Araújo – 574297

Disciplina: Inteligência Artificial

Professor: José Antonio Macedo

Fortaleza – CE

2026

1 Introdução e motivação do problema

Prontos-socorros brasileiros frequentemente enfrentam superlotação, longos tempos de espera e necessidade de priorizar pacientes em condições clínicas diferentes. A triagem manual, embora essencial, pode ser afetada por subjetividade, pressão operacional e dificuldade de acompanhar o risco de deterioração dos pacientes que permanecem aguardando atendimento.

Este trabalho propõe um sistema inteligente de apoio à triagem em pronto-socorro, combinando duas técnicas clássicas de Inteligência Artificial: Redes Bayesianas e algoritmo A*. A Rede Bayesiana estima a gravidade clínica de cada paciente a partir de sintomas e sinais vitais, enquanto o A* utiliza essa informação para ordenar a fila de atendimento considerando simultaneamente gravidade e tempo de espera.

O problema possui natureza probabilística e sequencial. Ele é probabilístico porque a gravidade real do paciente não é conhecida diretamente, mas inferida a partir de evidências como febre, saturação de oxigênio, pressão arterial, frequência cardíaca, dor, idade e doença crônica. Ele também é sequencial porque a escolha do próximo paciente atendido altera o risco acumulado dos demais pacientes que continuam esperando.

O objetivo geral é implementar e avaliar um sistema inteligente capaz de estimar a gravidade dos pacientes e sugerir uma ordem de atendimento que reduza o risco acumulado da fila. Como objetivos específicos, busca-se: construir uma Rede Bayesiana com variáveis clínicas relevantes; definir CPTs coerentes com a lógica de triagem; realizar inferência probabilística; formular a ordenação da fila como problema de busca; implementar o algoritmo A*; integrar a probabilidade de gravidade ao custo de espera; e comparar os resultados com estratégias FIFO e gulosa.

2 Modelagem da Rede Bayesiana

A Rede Bayesiana foi utilizada para representar relações probabilísticas entre sinais clínicos observáveis e a variável central Gravidade. Redes Bayesianas constituem modelos gráficos probabilísticos amplamente utilizados para representar dependências condicionais e realizar inferência sob incerteza, sendo uma abordagem consolidada na literatura de Inteligência Artificial (PEARL, 1988; KOLLER; FRIEDMAN, 2009). A rede possui nove variáveis: Febre, Saturação, Pressão, Frequência, Dor, Idade, Doença Crônica, Gravidade e Risco de Deterioração. As variáveis clínicas apontam para Gravidade, e Gravidade aponta para Risco de Deterioração.

Tabela 1: Variáveis e estados da Rede Bayesiana.

Variável	Estados
Febre	não, moderada, alta
Saturação	normal, reduzida, crítica
Pressão	normal, baixa, alta
Frequência	normal, elevada, crítica
Dor	leve, moderada, intensa
Idade	jovem, adulto, idoso
Doença Crônica	não, sim
Gravidade	baixa, média, alta
Risco de Deterioração	baixo, médio, alto

Estrutura da Rede Bayesiana implementada




Figura 1: Estrutura da Rede Bayesiana utilizada no sistema.

As CPTs das variáveis de entrada foram modeladas como distribuições marginais plausíveis para uma população simulada de pronto-socorro. A CPT de Gravidade foi gerada automaticamente por uma função de escore clínico: estados mais críticos receberam pesos maiores, como saturação crítica, frequência crítica, pressão baixa, idade idosa e presença de doença crônica. Em seguida, o escore foi convertido em probabilidades para os estados baixa, média e alta, com normalização para garantir soma igual a 1.

Os valores utilizados nas CPTs foram definidos por modelagem heurística baseada na lógica do Protocolo de Manchester e em critérios clínicos gerais de gravidade. Como o projeto possui finalidade acadêmica e não houve acesso a uma base hospitalar real, as probabilidades não devem ser interpretadas como valores clinicamente calibrados, mas como aproximações plausíveis para demonstrar a integração entre inferência probabilística e tomada de decisão.

No exemplo de inferência, um paciente com febre alta, saturação reduzida, pressão baixa, frequência elevada, dor intensa, idade idosa e doença crônica apresentou alta pro-

babilidade posterior de gravidade elevada. Esse resultado é coerente com o conjunto de evidências críticas observadas e permite transformar sintomas e sinais vitais em uma medida probabilística usada pelo módulo de busca.

3 Formulação do problema de busca

A ordenação da fila foi formulada como um problema de busca. O estado representa o conjunto ordenado de pacientes já atendidos; o estado inicial é a sequência vazia; a ação consiste em escolher o próximo paciente entre os ainda não atendidos; e o objetivo é alcançar um estado em que todos os pacientes tenham sido atendidos.

O custo de uma ação é calculado a partir do risco acumulado pelos pacientes que continuam aguardando. O risco individual considera a probabilidade de gravidade alta estimada pela Rede Bayesiana e o tempo de espera do paciente:

$$R(p) = P(\text{Gravidade} = \text{alta} \mid \text{evidências}_p) \times \text{Tempo}_p.$$

A função de avaliação do A^* é dada por:

$$f(n) = g(n) + h(n),$$

em que $g(n)$ representa o custo acumulado até o estado atual e $h(n)$ estima o custo restante. A heurística utilizada foi a soma dos riscos atuais dos pacientes ainda não atendidos. Essa heurística é otimista no cenário completo, pois considera o risco atual dos pacientes restantes sem acrescentar todo o aumento futuro de tempo de espera.

O espaço de busca cresce de forma fatorial, pois para n pacientes existem $n!$ possíveis ordens de atendimento. Por esse motivo, o A^* completo foi utilizado no cenário pequeno, enquanto no cenário médio foi utilizada uma versão limitada, com restrição no número de expansões e poda de candidatos. Essa adaptação torna a execução viável, mas remove a garantia formal de otimalidade do A^* completo.

4 Integração entre os módulos

A integração entre a Rede Bayesiana e o A^* ocorre por meio da probabilidade de gravidade alta. Para cada paciente, o sistema recebe evidências clínicas, executa inferência probabilística e calcula a distribuição posterior de Gravidade. Em seguida, a probabilidade $P(\text{Gravidade} = \text{alta})$ é combinada com o tempo de espera para gerar o risco atual do paciente.

Fluxo completo do sistema inteligente de triagem




Figura 2: Fluxo de integração entre inferência probabilística e busca heurística.

Sem a Rede Bayesiana, o A* não teria uma medida probabilística de gravidade clínica. Sem o A*, a probabilidade estimada pela rede seria apenas uma informação isolada, sem produzir uma política de atendimento. A integração transforma a inferência clínica em decisão operacional, permitindo que a fila seja ordenada pelo risco acumulado de deterioração.

5 Experimentos e resultados

Os experimentos compararam três estratégias de ordenação. A estratégia FIFO atende os pacientes na ordem de chegada e ignora a gravidade. A estratégia gulosa atende sempre o paciente com maior probabilidade de gravidade alta, ignorando explicitamente o tempo de espera. O A* considera simultaneamente a gravidade estimada e o tempo de espera,

buscando reduzir o risco acumulado total.

Tabela 2: Comparação conceitual entre as estratégias.

Estratégia	Gravidade	Tempo de espera	Busca sistemática
FIFO	Não	Sim, apenas ordem de chegada	Não
Gulosa	Sim	Não	Não
A*	Sim	Sim	Sim

5.1 Cenário pequeno

No cenário pequeno, foram simulados 8 pacientes. O A* completo foi executado sem poda, permitindo explorar o espaço de busca de forma sistemática.

Tabela 3: Risco acumulado total no cenário pequeno.

Estratégia	Risco acumulado total
FIFO	394,25
Gulosa	186,04
A*	176,78




Figura 3: Comparação do risco acumulado no cenário pequeno.

O FIFO apresentou o maior risco acumulado, pois não considera a gravidade dos pacientes. A estratégia gulosa reduziu substancialmente o risco ao priorizar pacientes com maior probabilidade de gravidade alta. O A* obteve o menor valor, mostrando que considerar simultaneamente gravidade e tempo de espera produz uma decisão globalmente melhor do que escolher apenas o paciente mais grave em cada passo.

5.2 Cenário médio

No cenário médio, foram simulados 25 pacientes. Devido ao crescimento fatorial do espaço de busca, foi utilizada uma versão limitada do A*, com limite de expansões e poda de candidatos.

Tabela 4: Risco acumulado total no cenário médio.

Estratégia	Risco acumulado total
FIFO	11784,04
Gulosa	4389,76
A* limitado	5006,92




Figura 4: Comparação do risco acumulado no cenário médio.

No cenário médio, a estratégia gulosa apresentou menor risco acumulado que o A* limitado. Embora o enunciado do trabalho espere que o algoritmo A* produza a solução de menor custo, essa propriedade é garantida apenas para a versão completa do algoritmo, desde que a heurística seja admissível e todo o espaço de busca possa ser explorado. Neste trabalho, devido ao crescimento fatorial do número de estados, foi adotada uma versão limitada do A*, com poda de candidatos e restrição no número de expansões para tornar a execução computacionalmente viável. Essa adaptação transforma o algoritmo em uma busca aproximada, removendo a garantia formal de otimalidade. Assim, o desempenho inferior ao da estratégia gulosa nesse cenário decorre da aproximação empregada e não da formulação original do A*, evidenciando o compromisso entre qualidade da solução e custo computacional em problemas de maior escala.

6 Conclusão

O sistema desenvolvido atendeu ao objetivo central do trabalho: integrar uma Rede Bayesiana e um algoritmo de busca para apoiar a triagem em pronto-socorro. A Rede Bayesiana

permitiu estimar probabilisticamente a gravidade dos pacientes a partir de sintomas e sinais vitais, enquanto o A* utilizou essa probabilidade no cálculo do risco acumulado da fila.

O que funcionou melhor foi a integração entre os módulos e o desempenho do A* no cenário pequeno, em que a busca completa obteve o menor risco acumulado entre as estratégias avaliadas. A comparação com FIFO e gulosa mostrou que incorporar informação probabilística e tempo de espera melhora a priorização em relação a critérios simples.

O principal ponto que não funcionou plenamente foi a escalabilidade do A* completo. No cenário médio, a versão limitada tornou a execução viável, mas perdeu a garantia de otimalidade e foi superada pela estratégia gulosa. Além disso, as CPTs foram definidas por plausibilidade clínica, não por calibração com dados reais, o que limita qualquer interpretação prática do sistema.

Como melhorias futuras, recomenda-se calibrar as CPTs com bases hospitalares reais ou validação de especialistas, testar funções de deterioração não lineares, considerar tempos de atendimento variáveis, incluir chegada dinâmica de novos pacientes e comparar o A* com alternativas como Beam Search, algoritmos anytime e meta-heurísticas. Dessa forma, o sistema poderia se aproximar melhor das condições reais de um pronto-socorro, mantendo a explicabilidade e a integração entre inferência probabilística e tomada de decisão.

Em síntese, o trabalho demonstrou que a combinação entre Redes Bayesianas e busca heurística constitui uma abordagem consistente para apoiar sistemas inteligentes de triagem. Mesmo utilizando um modelo simplificado e desenvolvido para fins acadêmicos, a solução proposta evidencia como técnicas clássicas de Inteligência Artificial podem ser integradas para representar incerteza, apoiar decisões e otimizar processos em cenários complexos

Referências

- [1] MACKWAY-JONES, K.; MARSDEN, J.; WINDLE, J. *Emergency Triage: Manchester Triage Group*. 3. ed. Wiley-Blackwell, 2014.
- [2] PEARL, J. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann, 1988.
- [3] RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2021.
- [4] HART, P. E.; NILSSON, N. J.; RAPHAEL, B. A formal basis for the heuristic determination of minimum cost paths. *IEEE Transactions on Systems Science and Cybernetics*, v. 4, n. 2, p. 100–107, 1968.
- [5] KOLLER, D.; FRIEDMAN, N. *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, 2009.
- [6] PGMPY. *pgmpy: Probabilistic Graphical Models using Python*. Disponível em: <https://pgmpy.org/>. Acesso em: 06 jul. 2026.