

Sistema Inteligente de Triagem em Pronto-Socorro

Disciplina de Inteligência Artificial

Professor: José Antonio Macedo

Francisco Wilton (508586) & Jardel de Araújo (574297)

Universidade Federal do Ceará – 2026

1. Introdução e Motivação

O Problema no Pronto-Socorro

- ✓ Superlotação e longos tempos de espera em unidades de saúde.
- ✓ Triage manual sujeita a subjetividade e forte pressão operacional.
- ✓ Dificuldade no acompanhamento contínuo do risco de deterioração clínica.


Objetivo Geral: Implementar e avaliar um sistema inteligente capaz de estimar a gravidade dos pacientes e sugerir uma ordem de atendimento que reduza o risco acumulado da fila.



Paciente → Triage → Espera → Atendimento

2. Modelagem da Rede Bayesiana

Estrutura da Rede Bayesiana implementada



Estrutura e Dependências

O modelo gráfico probabilisticamente representa a incerteza clínica associada à triagem.

- ✓ **7 Variáveis de Entrada:** Febre, Saturação, Pressão, Frequência, Dor, Idade e Doença Crônica.
- ✓ **Nó Central:** Gravidade (Baixa, Média, Alta).
- ✓ **Nó de Saída:** Risco de Deterioração (Baixo, Médio, Alto).

*Implementado via biblioteca **pgmpy** no ecossistema Python.*

2.1 Geração da CPT de Gravidade

Função de Escore Clínico

Devido ao número de pais, a CPT foi populada mapeando combinações de estados para pesos heurísticos inspirados no Protocolo de Manchester.

A probabilidade de gravidade alta aumenta conforme os marcadores clínicos se desviam do padrão normal.

```
p_alta = 1 / (1 + exp(-(escore - 8) / 2))  
p_baixa = 1 / (1 + exp((escore - 5) / 2))  
p_media = max(0.01, 1 - p_alta - p_baixa)
```

Pesos heurísticos usados na geração da CPT de Gravidade

Condição clínica	Peso
Saturação crítica	5
Frequência crítica	4
Pressão baixa	3
Saturação reduzida	3
Doença crônica: sim	2
Idade idoso	2
Dor intensa	2

2.2 Exemplo de Inferência (Variable Elimination)

Resultados do Módulo Probabilístico

Inserindo o perfil crítico no algoritmo VariableElimination obtém-se:

- ✓ Probabilidade Gravidade Baixa: **0,41%**
- ✓ Probabilidade Gravidade Média: **1,39%**

Paciente utilizado no exemplo de inferência

Evidência	Valor
Febre	alta
Saturação	reduzida
Pressão	baixa
Frequência	elevada
Dor	intensa
Idade	idoso
Doença crônica	sim

✓ Probabilidade Gravidade Alta: **98,20%****98.2%****P(Gravidade = alta) repassada ao A***

3. Formulação do Problema de Busca

Modelagem do sequenciamento da fila de triagem como um grafo de estados clássico em IA.



Estado

Conjunto ordenado de pacientes que já receberam atendimento na simulação (sequência inicial vazia).



Ação

Selecionar e retirar o próximo paciente da lista de espera para encaminhar ao atendimento.



Custos e Avaliação



Objetivo

$g(n)$: Risco acumulado. Cada atendimento consome 10 min, incrementando a espera dos remanescentes.

Heurística $h(n)$: Soma dos riscos atuais dos restantes (admissível e otimista).

Alcançar uma folha na árvore onde todos os pacientes foram alocados, minimizando o risco acumulado global.


3.1 Espaço de Busca e Expansão

4. Integração dos Módulos


Arquitetura em Pipeline

- ✓ A **Rede Bayesiana** processa a incerteza dos sinais clínicos subjetivos e gera a métrica estável de probabilidade.
- ✓ O **Algoritmo A*** absorve a probabilidade combinada ao tempo, gerenciando o comportamento dinâmico do custo sequencial.
- ✓ **Sinergia:** Sem a inferência, a busca careceria de peso clínico. Sem a busca, a inferência seria apenas um dado estático e isolado.

Fluxo completo do sistema inteligente de triagem



5. Experimentos: Cenário Pequeno (8 Pacientes)




Análise de Performance

A busca exaustiva do A^* encontrou a sequência ótima global de atendimento.

Estratégia	Risco Acumulado Total
FIFO (Chegada)	394,25
Gulosa (Apenas Gravidade)	186,04
A* Completo	176,78

O A^* superou a heurística Gulosa por balancear o agravamento dos pacientes de médio risco que aguardavam há muito tempo.

5.1 Experimentos: Cenário Médio (25 Pacientes)



O Impacto da Poda

Estratégia	Risco Acumulado Total
FIFO	11.784,04
Gulosa	4.389,76
A* Limitado (30k exp.)	5.006,92

Compromisso Computacional

Como o espaço de busca foi severamente restrito para viabilizar a execução, a perda de otimalidade fez com que a Gulosa performasse melhor. O resultado demonstra o desafio prático de escalabilidade em árvores fatoriais.

6. Conclusão e Trabalhos Futuros

O que funcionou

- ✓ A integração robusta entre inferência e busca sequencial transformou dados de sintomas em decisões operacionais.
- ✓ Desempenho ideal no cenário reduzido, mitigando riscos em relação ao método tradicional.

Limitações e Futuro

- ✓ **Limitação:** Escalabilidade do A^* exato e dependência de CPTs estimadas heurísticamente.
- ✓ **Evolução:** Investigar meta-heurísticas ou *Beam Search*, aplicar bases de dados hospitalares reais e prever a chegada dinâmica de novos pacientes.

Referências Bibliográficas

- [1] MACKWAY-JONES, K.; MARSDEN, J.; WINDLE, J. **Emergency Triage: Manchester Triage Group**. 3. ed. Wiley-Blackwell, 2014.
- [2] PEARL, J. **Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference**. Morgan Kaufmann, 1988.
- [3] RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4. ed. Pearson, 2021.
- [4] KOLLER, D.; FRIEDMAN, N. **Probabilistic Graphical Models: Principles and Techniques**. MIT Press, 2009.

[5] HART, P. E.; NILSSON, N. J.; RAPHAEL, B. A formal basis for the heuristic determination of minimum cost paths. **IEEE Transactions on Systems Science and Cybernetics**, v. 4, n. 2, p. 100–107, 1968.